

## Resumo de Inferência Estatística

### Sumário

- Aula 1: O que é e para que serve Inferência Estatística?
- Aula 2: Distribuição a priori e a posteriori
- Aula 3: Prioris conjugadas e função de perda
- Aula 4: Estimadores de Bayes e EMV
- Aula 5: EMV
- Aula 6: Método dos momentos e suficiência
- Aula 7: Suficiência conjunta e mínima, teorema de Rao-Blackwell
- Aula 8: Admissibilidade e viés
- Aula 9: Eficiência
- Aula 10: Distribuição de uma estatística amostral e qui-quadrado
- Aula 11: Distribuição da média e variância amostrais
- Aula 12: Distribuição t de Student e intervalos de confiança
- Aula 13: Intervalos de confiança e Quantidades Pivotalis
- Aula 14: Testes de hipótese I
- Aula 15: Testes de hipótese II
- Aula 16: Testes de hipótese III
- Aula 17: Testes e conjuntos de confiança
- Aula 18: Teste t I
- Aula 19: Teste t II
- Aula 20: Teste f
- Aula 21: Regressão Linear I
- Aula 22: Regressão Linear II

## Aula 1: O que é e para que serve Inferência Estatística?

**Definição 1 (Modelo estatístico: informal)** Um *modelo estatístico* consiste na identificação de variáveis aleatórias de interesse (observáveis e potencialmente observáveis), na especificação de uma distribuição conjunta para as variáveis aleatórias observáveis e na identificação dos parâmetros ( $\theta$ ) desta distribuição conjunta. Às vezes é conveniente assumir que os parâmetros são variáveis aleatórias também, mas para isso é preciso especificar uma distribuição conjunta para  $\theta$ .

**Definição 2 (Modelo estatístico: formal)** Seja  $\mathcal{X}$  um espaço amostral qualquer,  $\Theta$  um conjunto não-vazio arbitrário e  $\mathcal{P}(\mathcal{X})$  o conjunto de todas as distribuições de probabilidade em  $\mathcal{X}$ . Um modelo estatístico *paramétrico* é uma função  $P : \Theta \rightarrow \mathcal{P}(\mathcal{X})$  que associa a cada  $\theta \in \Theta$  uma distribuição de probabilidade  $P_\theta$  em  $\mathcal{X}$ .

**Definição 3 (Afirmção probabilística)** Dizemos que uma afirmação é *probabilística* quando ela utiliza conceitos da teoria de probabilidade para falar de um objeto.

**Definição 4 (Inferência Estatística)** Uma *inferência estatística* é uma *afirmação probabilística* sobre uma ou mais partes de um modelo estatístico.

**Definição 5 (Estatística)** Suponha que temos uma coleção de variáveis aleatórias  $X_1, X_2, \dots, X_n \subseteq \mathbb{R}^n$  e uma função  $r : \mathbf{X} \rightarrow \mathbb{R}^m$ . Dizemos que a variável aleatória  $T = r(X_1, X_2, \dots, X_n)$  é uma *estatística*.

**Definição 6 (Permutabilidade)** Uma coleção finita de variáveis aleatórias  $X_1, X_2, \dots, X_n$  com densidade conjunta  $f$  é dita *permutável* se

$$f(x_1, x_2, \dots, x_n) = f(x_{\pi(1)}, x_{\pi(2)}, \dots, x_{\pi(n)}) \quad (1)$$

para qualquer permutação  $\pi = \{\pi(1), \pi(2), \dots, \pi(n)\}$  dos seus elementos. Uma coleção finita é permutável se qualquer subconjunto finito é permutável.

## Aula 2: Distribuição a priori e a posteriori

**Definição 7 (Distribuição a priori)** Se tratamos o parâmetro  $\theta$  como uma variável aleatória, então a *distribuição a priori* é a distribuição que damos a  $\theta$  antes de observarmos as outras variáveis aleatórias de interesse. Vamos denotar a função de densidade/massa de probabilidade da priori por  $\xi(\theta)$ .

**Definição 8 (Distribuição a posteriori)** Considere o problema estatístico com parâmetros  $\theta$  e variáveis aleatórias observáveis  $X_1, X_2, \dots, X_n$ . A distribuição condicional de  $\theta$  dados os valores observados das variáveis aleatórias,  $\mathbf{x} := \{x_1, x_2, \dots, x_n\}$  é a *distribuição a posteriori* de  $\theta$ , denotamos por  $\xi(\theta | \mathbf{x})$  a f.d.p./f.m.p. condicional a  $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ .

**Teorema 1 (Distribuição a posteriori: derivação)** Considere a amostra aleatória  $X_1, X_2, \dots, X_n$  de uma distribuição com f.d.p./f.m.p.  $f(x | \theta)$ . Se a distribuição a priori é  $\xi(\theta)$ , temos

$$\xi(\theta | \mathbf{x}) = \frac{\xi(\theta) \prod_{i=1}^n f(x_i | \theta)}{g_n(\mathbf{x})}, \quad \theta \in \Omega \quad (2)$$

Chamamos  $g_n(\mathbf{x})$  de distribuição marginal de  $X_1, X_2, \dots, X_n$ .

**Definição 9 (Função de verossimilhança)** Quando encaramos a f.d.p./f.m.p.  $f(x_1, x_2, \dots, x_n | \theta)$  como uma função do parâmetro  $\theta$ , chamamos esta função de *função de verossimilhança*, e podemos denotá-la como  $L(\theta; \mathbf{x})$  ou, quando a notação não criar ambiguidade, simplesmente  $L(\theta)$ .

## Aula 3: Prioris conjugadas e função de perda

**Definição 10 (Hiper-parâmetros)** Seja  $\xi(\theta | \phi)$  a distribuição a priori para o parâmetro  $\theta$ , indexada por  $\phi \in \Phi$ . Dizemos que  $\phi$  é(são) o(s) **hiper-parâmetro(s)** da priori de  $\theta$ .

**Definição 11 (Priori conjugada)** Suponha que  $X_1, X_2, \dots$  sejam condicionalmente independentes dado  $\theta$ , com f.d.p./f.m.p.  $f(x | \theta)$ . Defina

$$\Psi = \left\{ f : \Omega \rightarrow (0, \infty), \int_{\Omega} f dx = 1 \right\} \quad (3)$$

onde  $\Omega$  é o espaço de parâmetros. Dizemos que  $\Psi$  é uma **família de distribuições conjugadas** para  $f(x | \theta)$  se  $\forall f \in \Psi$  e toda realização  $\mathbf{x}$  de  $X = X_1, X_2, \dots, X_n$

$$\frac{f(\mathbf{x} | \theta)f(\theta)}{\int_{\Omega} f(\mathbf{x} | \theta)f(\theta)d\theta} \in \Psi \quad (4)$$

**Teorema 2 (Distribuição a posteriori da média de uma normal)** Suponha que  $X_1, X_2, \dots, X_n$  formam uma amostra aleatória com distribuição normal e com média desconhecida  $\theta$  e variância  $\sigma^2 > 0$ , conhecida e fixa. Suponha que  $\theta \sim \text{Normal}(\mu_0, v_0^2)$  a priori. Então

$$\xi(\theta | x, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\theta - \mu_1)^2}{2v_1^2}\right), \quad (5)$$

onde

$$\mu_1 := \frac{\sigma^2\mu_0 + nv_0^2\bar{x}_n}{\sigma^2 + nv_0^2} \text{ e } v_1^2 := \frac{\sigma^2v_0^2}{\sigma^2 + nv_0^2} \quad (6)$$

**Definição 12 (Priori imprópria)** Seja  $\xi : \Lambda \rightarrow (0, \infty), \Omega \subseteq \Lambda$ , uma função tal que  $\int_{\Omega} \xi(\theta)d\theta = \infty$ . Se utilizamos  $\xi$  como uma p.d.f.<sup>1</sup> para  $\theta$ , dizemos que  $\xi$  é uma **priori imprópria** para  $\theta$ .

**Definição 13 (Estimador)** Sejam  $X_1, X_2, \dots, X_n$  variáveis aleatórias com distribuição conjunta indexada por  $\theta$ . Um **estimador** de  $\theta$  é qualquer função real  $\delta : X_1, X_2, \dots, X_n \rightarrow \mathbb{R}^d, d \geq 1$ .

**Definição 14 (Estimativa)** Dizemos que o valor de  $\delta$  avaliado nas realizações de  $X_1, X_2, \dots, X_n$ ,  $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$ ,  $\delta(\mathbf{x})$  é uma **estimativa** de  $\theta$ .

**Definição 15 (Função de perda)** Uma função de perda é uma função real em duas variáveis

$$L : \Omega \times \mathbb{R}^d \rightarrow \mathbb{R}, \quad (7)$$

em que dizemos que o estatístico perde  $L(\theta, a)$  se o parâmetro vale  $\theta$  e a estimativa dada vale  $a$ .

## Famílias Conjugadas

Se  $X_1, \dots, X_n$  são iid e seguem a distribuição da coluna “Dados” na tabela 1.

**Notações:**  $\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$ ;  $y = \sum_{i=1}^n x_i$

---

<sup>1</sup>p.d.f. - “probability density function” ou função de densidade de probabilidade

Dados	Priori	Posteriori
Bernoulli( $\theta$ )	Beta( $\alpha, \beta$ )	Beta( $\alpha + y, \beta + n - y$ )
Poisson( $\theta$ )	Gama( $\alpha, \beta$ )	Gama( $\alpha + y, \beta + n$ )
Normal( $\mu, \sigma^2$ )	Normal( $\mu_0, v_0^2$ )	Normal( $\frac{\sigma^2 \mu_0 + n v_0^2 \bar{x}_n}{\sigma^2 + n v_0^2}, \frac{\sigma^2 v_0^2}{\sigma^2 + n v_0^2}$ )
Exp( $\theta$ )	Gama( $\alpha, \beta$ )	Gama( $\alpha + n, \beta + y$ )

Table 1: Famílias Conjugadas

## Aula 4: Estimadores de Bayes e EMV

**Definição 16 (Estimador de Bayes)** Considere a perda esperada a posteriori:

$$E_{\theta|x}[L(\theta, a)] = E[L(\theta, a) | x] = \int_{\Omega} L(\theta, a) \xi(\theta | x) d\theta \quad (8)$$

Dizemos que  $\delta^*$  é um **estimador de Bayes** se, para toda realização  $X = x$ ,

$$E[L(\theta, \delta^*(x)) | x] = \min_{a \in A} E[L(\theta, a) | x]. \quad (9)$$

Em outras palavras, um estimador de Bayes é uma função real dos dados que minimiza a perda esperada com respeito à posteriori dos parâmetros.

**Teorema 3 ( $\delta^*$  sob perda quadrática)** Seja  $\theta$  um parâmetro tomando valores reais. Sob perda quadrática,

$$\delta^*(x) = E[\theta | X = x] = \int_{\Omega} \theta \xi(\theta | x) d\theta \quad (10)$$

**Teorema 4 ( $\delta^*$  sob perda absoluta)** Suponha que a função de perda é dada por

$$L(\theta, \delta^*) = |\theta - \delta^*|. \quad (11)$$

Dizemos que a função de perda é **absoluta**. Seja  $\theta$  um parâmetro tomando valores na reta. Sob perda absoluta,  $\delta^*(x)$  é a **mediana** a posteriori, isto é,

$$\int_{-\infty}^{\delta^*(x)} \xi(\theta | x) d\theta = \frac{1}{2} \quad (12)$$

**Definição 17 (Estimador consistente)** Seja  $\delta_1, \delta_2, \dots, \delta_n$  uma sequência de estimadores de  $\theta$ . Se quando  $n \rightarrow \infty$  a sequência convergente para  $\theta$ , dizemos que esta é uma **sequência consistente de estimadores**.

**Definição 18 (Estimador de máxima verossimilhança)** Para cada possível vetor (de observações)  $x$ , seja  $\delta(x) \in \Omega$  um valor de  $\theta \in \Omega$  de modo que a função de verossimilhança,  $L(\theta) \propto f(x | \theta)$  <sup>2</sup>, atinge o máximo. Dizemos que  $\hat{\theta} = \delta(\mathbf{X})$  é o **estimador de máxima verossimilhança** de  $\theta$  (Fisher, 1922)<sup>3</sup>. Quando observamos  $\mathbf{X} = x$ , dizemos que  $\delta(x)$  é uma estimativa de  $\theta$ . Dito de outra forma:

$$\max_{\theta \in \Omega} f(\mathbf{X} | \theta) = f(\mathbf{X} | \hat{\theta}). \quad (13)$$

<sup>2</sup> $\propto$  - é um operador matemático binário que indica que o valor esquerdo é proporcional ao valor direito.

<sup>3</sup>Ronald Aylmer Fisher (1890-1962), biólogo e estatístico inglês.

## Aula 5: EMV

**Teorema 5 (Invariância do EMV)** Considere uma função  $\phi : \Omega \rightarrow \mathbb{R}$ . Se  $\hat{\theta}$  é um EMV para  $\theta$ , então  $\phi(\hat{\theta})$  é um EMV para  $\omega = \phi(\theta)$ .

**Teorema 6 (Consistência do EMV)** Defina  $l(\theta) := \log f_n(x | \theta)$  e assumamos que  $X_1, \dots, X_n \sim f(\theta_0)$ , isto é, que  $\theta_0$  é o valor verdadeiro do parâmetro. Denote  $E_{\theta_0}[g] := \int_{\mathcal{X}} g(x, \theta_0) f(x | \theta_0) dx$ . Suponha que

- $f(x_i | \theta)$  tem o mesmo suporte;
- $\theta_0$  é o ponto inferior de  $\Omega$ ;
- $I(\theta)$  é diferenciável;
- $\hat{\theta}_{EMV}$  é única solução de  $I'(\theta) = 0$ .

Então

$$\hat{\theta}_{EMV} \rightarrow \theta$$

## Aula 6: Método dos momentos e suficiência

**Definição 19 (Método dos momentos)** Suponha que  $X_1, \dots, X_n$  formam uma sequência aleatória com distribuição conjunta  $f_n(X_1, \dots, X_n | \theta)$ ,  $\theta \in \Omega \subseteq \mathbb{R}^k$  e que o  $k$ -ésimo momento existe. Defina  $\mu_j(\theta) = E[X_1^j | \theta]$  e suponha que  $\mu : \Omega \rightarrow \mathbb{R}^k$  é biunívoca, de modo que sua inversa é

$$\theta = M(\mu_1(\theta), \dots, \mu_k(\theta)).$$

Dados os momentos amostrais  $m_j := \frac{1}{n} \sum_{i=1}^n X_i^j$ ,  $j = 1, \dots, k$  o **estimador de momentos (EMM)** de  $\theta$  é

$$\hat{\theta}_{EMM} = M(m_1, \dots, m_k).$$

**Teorema 7 (Consistência do EMM)** Suponha que  $X_1, \dots, X_n$  formam uma amostra aleatória com distribuição conjunta  $f_n(X_1, \dots, X_n | \theta)$ ,  $\theta \in \Omega \subseteq \mathbb{R}^k$  e que o  $k$ -ésimo momento existe. Suponha que a inversa  $M$  existe e é contínua. Então o EMM é **consistente** para  $\theta$ .

**Definição 20 (Estatística suficiente)** Seja  $X_1, \dots, X_n$  uma amostra aleatória de uma distribuição indexada pelo parâmetro  $\theta$ . Seja  $T = r(X_1, \dots, X_n)$  uma estatística. Dizemos que  $T$  é uma **estatística suficiente** para  $\theta$  se e somente se

$$f(X_1, \dots, X_n | T = t, \theta) = f(X_1, \dots, X_n | T = t, \theta'), \forall \theta, \theta' \in \Omega, \quad (14)$$

isto é, se a distribuição condicional da amostra dado o valor da estatística não depende de  $\theta$ .

**Definição 21 (Aleatorização auxiliar)** Suponha que  $T$  é suficiente para  $\theta$ . O processo de simular  $X'_1, \dots, X'_n$  dado que  $T = r(X_1, \dots, X_n)$  de modo que

$$f(X_1, \dots, X_n | \theta) = f(X'_1, \dots, X'_n | \theta), \forall \theta \in \Omega, \quad (15)$$

é chamado de **aleatorização auxiliar** (em inglês, *auxiliary randomisation*).

**Teorema 8 (Teorema de fatorização)** Suponha que  $X_1, \dots, X_n$  perfazem uma amostra aleatória com f.d.p./f.m.p.  $f(x | \theta)$ ,  $\theta \in \Omega$ . Uma estatística  $T = r(X_1, \dots, X_n)$  é suficiente para  $\theta$  se, e somente se, para todo  $x \in \mathcal{X}$  e  $\theta \in \Omega$  existem  $u$  e  $v$  não negativos tal que

$$f_n(x | \theta) = u(x)v[r(x), \theta]. \quad (16)$$

**Definição 22 (Suficiência conjunta)** Dizemos que um conjunto de estatísticas  $T = \{T_1, \dots, T_n\}$  é **suficiente** (conjuntamente) se que a distribuição condicional conjunta de  $X_1, \dots, X_n$  dado  $T_1 = t_1, \dots, T_n = t_n$  não dependem de  $\theta$ .

## Aula 7: Suficiência conjunta e mínima, teorema de Rao-Blackwell

**Definição 23 (Estatísticas de ordem)** Seja  $\mathbf{X} = X_1, \dots, X_n$  uma amostra aleatória. Dizemos que  $Y_1, \dots, Y_n$  são **estatísticas de ordem** se  $Y_1$  é o menor valor de  $\mathbf{X}$ ,  $Y_2$  é o segundo menor valor e assim sucessivamente.

**Teorema 9 (Estatísticas de ordem são suficientes conjuntas)** Seja  $X_1, \dots, X_n$  uma amostra aleatória com f.d.p./f.m.p.  $f(\mathbf{x} | \theta)$ . As estatísticas de ordem  $Y_1, \dots, Y_n$  são suficientes conjuntas para  $\theta$ .

**Definição 24 (Suficiência mínima)** Uma estatística  $\mathbf{T}$  é dita **mínima suficiente** se  $\mathbf{T}$  é suficiente e é função de qualquer outra estatística suficiente. Um vetor  $\mathbf{T} = \{T_1, \dots, T_n\}$  é dito **minimamente suficiente conjunto** se é função de qualquer outro valor de estatísticas suficientes conjuntas.

**Teorema 10 (EMV e Bayes são suficientes)** Se a função de verossimilhança admite fatorização pelo Teorema 8, os estimadores de Bayes e de máxima verossimilhança são estatísticas minimamente suficientes.

**Definição 25 (Notação conveniente)** É conveniente definir que para  $g : \mathcal{X}^n \rightarrow \mathbb{R}$ , escrevemos

$$E_\theta[g] = \int_{\mathcal{X}} \cdots \int_{\mathcal{X}} g(\mathbf{x}) f_n(\mathbf{x} | \theta) dx_1 \cdots dx_n = \int_{\mathcal{X}} g(\mathbf{x}) f_n(\mathbf{x} | \theta) d\mathbf{x} \quad (17)$$

**Definição 26 (Erro quadrático médio)**

$$R(\theta, \delta) := E_\theta [\{\delta(\mathbf{X}) - \theta\}^2]. \quad (18)$$

**Definição 27 (Estimador condicionado)**

$$\delta_0(\mathbf{T}) := E_\theta [\delta(\mathbf{X}) | \mathbf{T}]. \quad (19)$$

**Teorema 11 (Teorema de Rao-Blackwell)** Seja  $\delta(\mathbf{X})$  um estimador,  $\mathbf{T}$  uma estatística suficiente para  $\theta$  e seja  $\delta_0(\mathbf{T})$  como na Definição 27. Então vale que

$$R(\theta, \delta_0) \leq R(\theta, \delta)$$

Além disso, se  $R(\theta, \delta) < \infty$  e  $\delta(\mathbf{X})$  não é função de  $\mathbf{T}$ , vale a desigualdade estrita:

$$R(\theta, \delta_0) < R(\theta, \delta)$$

## Aula 8: Admissibilidade e viés

**Definição 28 (Admissibilidade)** Um estimador  $\delta$  é dito **inadmissível** se existe outro estimador  $\delta_0$  tal que  $R(\theta, \delta_0) \leq R(\theta, \delta), \forall \theta \in \Omega$  e existe  $\theta' \in \Omega$  tal que  $R(\theta', \delta_0) < R(\theta', \delta)$ . Nesse caso, dizemos que  $\delta_0$  domina  $\delta$ . O estimador  $\delta_0$  é **admissível** se (e somente se) não há nenhum estimador que o domine.

**Definição 29 (Estimador não-viesado)** Um estimador  $\delta(\mathbf{X})$  de uma função  $g(\theta)$  é dito **não-viesado** se  $E_\theta[\delta(\mathbf{X})] = g(\theta), \forall \theta \in \Omega$ . Um estimador que não atende a essa condição é dito **viesado**. E o **viés** de  $\delta$  é definido como  $B_\delta(\theta) := E_\theta[\delta(\mathbf{X})] - g(\theta)$ .

**Teorema 12 (Estimador não-viesado da variância)** Seja  $\mathbf{X} = \{X_1, \dots, X_n\}$  uma amostra aleatória, com  $E[X_1] = m$  e  $Var(X_1) = v < \infty$ . Então

$$\delta_1(\mathbf{X}) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

é um estimador não-viesado de  $v$ .

## Aula 9: Eficiência

**Definição 30 (Informação de Fisher)** Seja  $X$  uma variável aleatória com f.d.p./f.m.p.  $f(x | \theta)$ ,  $\theta \in \Omega \subseteq \mathbb{R}$ . Suponha que  $f(x | \theta)$  é duas vezes diferenciável com respeito a  $\theta$ . Defina  $\lambda(x | \theta) = \log f(x | \theta)$  e

$$\lambda'(x | \theta) = \frac{\partial \lambda(x | \theta)}{\partial \theta} \quad \text{e} \quad \lambda''(x | \theta) = \frac{\partial^2 \lambda(x | \theta)}{\partial \theta^2} \quad (20)$$

Definimos a **informação de Fisher** como

$$I(\theta) = E_{\theta} [\{\lambda'(x | \theta)\}^2] \stackrel{(1)}{=} -E_{\theta} [\lambda''(x | \theta)] = \text{Var}_{\theta} (\lambda'(x | \theta)). \quad (21)$$

**Teorema 13 (Informação de Fisher em uma amostra aleatória)** Seja  $\mathbf{X} = \{X_1, \dots, X_n\}$  uma amostra aleatória e seja  $I_n = E_{\theta} [-\lambda''_n(\mathbf{X} | \theta)]$  a **informação de Fisher** da amostra. Então

$$I_n(\theta) = nI(\theta)$$

**Teorema 14 (Teorema de Cramér-Rao)** Seja  $\mathbf{X} = \{X_1, \dots, X_n\}$  uma amostra aleatória, onde f.d.p./f.m.p. tem as mesmas premissas da Definição 30. Supondo que  $T = r(\mathbf{X})$  é uma estatística com variância finita. Seja  $m(\theta) = E_{\theta}(T)$  uma função diferenciável de  $\theta$ . Então,

$$\text{Var}_{\theta}(T) \geq \frac{[m'(\theta)]^2}{nI(\theta)}, \quad (22)$$

com igualdade apenas se existem  $u$  e  $v$  tal que

$$T = u(\theta)\lambda'_n(\mathbf{X} | \theta) + v(\theta).$$

**Definição 31 (Estimador eficiente)** Um estimador  $\delta(\mathbf{X})$  é dito **eficiente** de (sua esperança)  $m(\theta)$  se

$$\text{Var}_{\theta}(\delta) = \frac{[m'(\theta)]^2}{nI(\theta)}.$$

## Aula 10: Distribuição de uma estatística amostral e qui-quadrado

**Definição 32 (Distribuição qui-quadrado)** Dizemos que uma variável aleatória  $Y$  tem distribuição **qui-quadrado** com  $m$  graus de liberdade quando

$$f_Y(y) = \frac{1}{2^{m/2}\Gamma(m/2)} y^{m/2-1} e^{-y/2}, y > 0 \quad (23)$$

Vemos que  $Y$  tem função geradora de momentos:

$$\psi(t) = \left( \frac{1}{1-2t} \right)^{m/2}, t < 1/2.$$

**Teorema 15 (Soma de variáveis aleatórias qui-quadrado)** Se  $X_1, \dots, X_n$  são variáveis aleatórias independentes com graus de liberdade  $m_i$ , então  $W = \sum_{i=1}^n X_i$  tem distribuição qui-quadrado com graus de liberdade  $m = \sum_{i=1}^n m_i$ .

**Teorema 16 (Distribuição do quadrado de uma variável aleatória Normal padrão)** Se

$$X \sim \text{Normal}(0, 1), Y = X^2$$

então, tem distribuição qui-quadrado com  $m = 1$ .

## Aula 11: Distribuição da média e variância amostrais

**Teorema 17 (Independência da média e variância amostrais na Normal)** Seja  $X_1, \dots, X_n$  uma amostra aleatória de uma distribuição Normal com parâmetros  $\mu$  e  $\sigma^2$ ,  $\bar{X}_n$  e a variância amostral  $\bar{S}_n^2$ , são independentes. Ademais,  $\bar{X}_n \sim \text{Normal}(\mu, \sigma^2)$  e  $\bar{S}_n^2 \sim \text{Gama}(\frac{n-1}{2}, \frac{n}{2n^2})$

## Aula 12: Distribuição t de Student e intervalos de confiança

**Definição 33 (A distribuição t de Student)** Tome,  $Y \sim \text{Qui-quadrado}(m)$  e  $Z \sim \text{Normal}(0, 1)$  e defina a variável aleatória

$$X = \frac{Z}{\sqrt{\frac{Y}{m}}}.$$

Dizemos que  $X$  tem distribuição **t de Student com  $m$  graus de liberdade**. E sabemos que

$$f_X = \frac{\Gamma(\frac{m+1}{2})}{\sqrt{m\pi}\Gamma(\frac{m}{2})} \left(1 + \frac{x^2}{m}\right)^{-\frac{m+1}{2}}, \quad x \in (-\infty, +\infty).$$

**Teorema 18 (Distribuição amostral do estimador não-viesado da variância)** Considere o estimador

$$\hat{\sigma}' = \sqrt{\frac{\Delta^2}{n-1}},$$

onde  $\Delta^2 = \sum_{i=1}^n (X_i - \bar{X}_n)^2$ . Então, vale que

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\hat{\sigma}'} \sim \text{Student}(n-1)$$

**Teorema 19 (Intervalo de confiança)** Seja  $\mathbf{X} = \{X_1, \dots, X_n\}$  uma amostra aleatória, onde cada uma tem p.d.f.  $f(x | \theta)$ , e considere uma função real  $g(\theta)$ . Sejam  $A(\mathbf{X})$  e  $B(\mathbf{X})$  duas estatísticas de modo de valha

$$P(A(\mathbf{X}) < g(\theta) < B(\mathbf{X})) \geq \gamma. \quad (24)$$

Dizemos que  $I(\mathbf{X}) = (A(\mathbf{X}), B(\mathbf{X}))$  é um **intervalo de confiança** de  $100\gamma\%$  para  $g(\theta)$ . Se a desigualdade for uma igualdade para todo  $\theta \in \Omega$ , dizemos que o intervalo é **exato**.

## Aula 13: Intervalos de confiança e Quantidades Pivotalis

**Definição 34 (Intervalo de confiança unilateral)** Seja  $\mathbf{X} = \{X_1, \dots, X_n\}$  uma amostra aleatória, onde cada uma tem p.d.f.  $f(x | \theta)$ , e considere uma função real  $g(\theta)$ . Seja  $A(\mathbf{X})$  uma estatística que

$$P(A(\mathbf{X}) < g(\theta)) \geq \gamma, \quad \forall \theta \in \Omega$$

dizemos que o intervalo aleatório  $(A(\mathbf{X}), \infty)$  é chamado de intervalo de confiança **unilateral** de  $100\gamma\%$  para  $g(\theta)$  (ou ainda, de intervalo de confiança **inferior** de  $100\gamma\%$  para  $g(\theta)$ ). O intervalo  $(-\infty, B(\mathbf{X}))$ , com

$$P(g(\theta) < B(\mathbf{X})) \geq \gamma, \quad \forall \theta \in \Omega$$

é definido de forma análoga, e é chamado de intervalo de confiança **superior** de  $100\gamma\%$  para  $g(\theta)$ . Se a desigualdade é uma igualdade para todo  $\theta \in \Omega$ , os intervalos são chamados **exatos**.



**Definição 35 (Quantidade pivotal)** Seja  $\mathbf{X} = \{X_1, \dots, X_n\}$  uma amostra aleatória com p.d.f.  $f(x | \theta)$ . Seja  $V(\mathbf{X}, \theta)$  uma variável aleatória cuja distribuição é a mesma para todo  $\theta \in \Omega$ . Dizemos que  $V(\mathbf{X}, \theta)$  é uma **quantidade pivotal**.

**Teorema 20 (Intervalo de confiança unilateral)** Seja  $\mathbf{X} = \{X_1, \dots, X_n\}$  uma amostra aleatória com p.d.f.  $f(x | \theta)$ . Suponha que existe uma quantidade pivotal  $V$ , com c.d.f.<sup>4</sup> continua  $G$ . Assuma que existe  $r(v, \mathbf{x})$  estritamente crescente em  $v$  para todo  $\mathbf{x}$ . Finalmente, tome  $0 < \gamma < 1$  e  $\gamma_1 < \gamma_2$  de modo que  $\gamma_2 - \gamma_1 = \gamma$ . Então as estatísticas

$$A(\mathbf{X}) = r(G^{-1}(\gamma_1), \mathbf{X}),$$

$$B(\mathbf{X}) = r(G^{-1}(\gamma_2), \mathbf{X}),$$

são os limites de um intervalo de confiança de  $100\gamma\%$  para  $g(\theta)$ .

## Aula 14: Testes de hipótese I

**Definição 36 (Hipótese nula e hipótese alternativa)** Considere o espaço de parâmetros  $\Omega$  e defina  $\Omega_0, \Omega_1 \subset \Omega$  de modo que  $\Omega_0 \cup \Omega_1 = \Omega$  e  $\Omega_0 \cap \Omega_1 = \emptyset$ . Definimos

$$H_0 := \theta \in \Omega_0,$$

$$H_1 := \theta \in \Omega_1,$$

E dizemos que  $H_0$  é a **hipótese nula** e  $H_1$  é a **hipótese alternativa**. Se  $\theta \in \Omega_1$ , então dizemos que rejeitamos a hipótese nula. Por outro lado, se  $\theta \in \Omega_0$ , então dizemos que não rejeitamos ou falhamos em rejeitar  $H_0$ .

**Definição 37 (Hipótese simples e hipótese composta)** Dizemos que uma hipótese  $H_i$ , é **simples**, se  $\Omega_i = \{\theta_i\}$ , isto é, se a partição correspondente é um único ponto. Uma hipótese é dita **composta** se não é simples.

**Definição 38 (Hipótese unilateral e hipótese bilateral)** Uma hipótese da forma  $H_0 : \theta \leq \theta_0$  ou  $H_0 : \theta \geq \theta_0$  é dita **unilateral** (“one-sided”), enquanto hipóteses da forma  $H_0 : \theta \neq \theta_0$  são ditas **bilaterais** (“two-sided”).

## Aula 15: Testes de hipótese II

**Definição 39 (Região crítica)** O conjunto

$$S_1 := \{\mathbf{x} : |\bar{X}_n - \mu_0| \geq c\}$$

é chamado de **região crítica** do teste.

**Definição 40 (Região de rejeição)** Se  $R \subseteq \mathbb{R}$  é tal que “rejeitamos  $H_0$  se  $T \in R$ ”, então  $R$  é chamada uma **região de rejeição** para a estatística  $T$  e o teste associado.

**Definição 41 (Função poder)** Seja  $\delta$  um procedimento de aceitação/rejeição como visto anteriormente. A **função poder** é definida como

$$\pi(\theta | \delta) := P(\mathbf{X} \in S_1 | \theta) = P(T \in R | \theta), \quad \theta \in \Omega \quad (25)$$

---

<sup>4</sup>c.d.f. - cumulative distribution function

**Definição 42 (Tipos de erros)** *Tipos de erros que podem ser cometidos*

Nome	Erro cometido
Erro tipo I	Rejeitar $H_0$ quando ela é <b>verdadeira</b> .
Erro tipo II	Falhar em rejeitar $H_0$ quando ela é <b>falsa</b> .

**Definição 43 (Tamanho/nível de um teste)** *Dizemos que um teste,  $\delta$ , tem **tamanho** ou **nível de significância**  $\alpha(\delta)$ , com*

$$\alpha(\delta) := \sup_{\theta \in \Omega_0} \pi(\theta \mid \delta).$$

## Aula 16: Testes de hipótese III

**Definição 44 (O p-valor)** *Para cada  $t$ , seja  $\delta_t$  o teste que rejeita  $H_0$  se  $T \geq t$ . Então, quando  $T = t$ , o **p-valor** vale*

$$p(t) := \sup_{\theta \in \Omega_0} \pi(\theta \mid \delta_t) = \sup_{\theta \in \Omega_0} P(T \geq t \mid \theta) \quad (26)$$

*ou seja, o **p-valor** é o tamanho do teste  $\delta_t$ .*

## Aula 17: Testes e conjuntos de confiança

**Definição 45 (Intervalos de confiança e testes são equivalentes)** *Suponha que dispomos de dados  $\mathbf{X} = \{X_1, \dots, X_n\}$  com f.d.p. comum  $f(x \mid \theta)$ , e estamos interessados em testar as hipóteses:*

$$H_0 : g(\theta) = g_0,$$

$$H_1 : g(\theta) \neq g_0,$$

*de modo que existe um teste  $\delta_{g_0}$  com nível  $\alpha_0$  destas hipóteses. Para cada  $\mathbf{X} = \mathbf{x}$ , defina*

$$w(\mathbf{x}) = \{g_0 : \delta_{g_0} \text{ não rejeita } H_0 \text{ dado que } \mathbf{X} = \mathbf{x}\}.$$

*Fazendo o nível de confiança do intervalo  $\gamma = 1 - \alpha_0$ , temos*

$$P(g(\theta_0) \in w(\mathbf{X}) \mid \theta = \theta_0) \geq \gamma, \quad \forall \theta_0 \in \Omega.$$

**Definição 46 (Conjunto de confiança)** *Se um conjunto aleatório  $w(\mathbf{X})$  satisfaz*

$$P(g(\theta_0) \in w(\mathbf{X}) \mid \theta = \theta_0) \geq \gamma,$$

*para todo  $\theta_0 \in \Omega$ , então chamamos  $w(\mathbf{X})$  de um **conjunto de confiança** para  $g(\theta)$ .*

**Teorema 21 (Testando hipóteses a partir de conjuntos de confiança)** *Suponha que dispomos de dados  $\mathbf{X} = \{X_1, \dots, X_n\}$  com f.d.p. comum  $f(x \mid \theta)$  e que  $w(\mathbf{X})$  é um conjunto de confiança para uma função de interesse  $g(\theta)$ . Então para todo valor  $g_0$  assumido por  $g(\theta)$  existe um teste  $\delta_{g_0}$ , de nível  $\alpha_0$  que rejeita  $H_0 : g(\theta) = g_0$  se e somente se  $g(\theta_0) = g_0 \notin w(\mathbf{X})$ .*

**Teorema 22 (Teste de razão de verossimilhanças (para o Teo. de Wilks))** *A estatística*

$$\Lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Omega_0} f_n(\mathbf{x} \mid \theta)}{\sup_{\theta \in \Omega} f_n(\mathbf{x} \mid \theta)}$$

*é chamada um **estatística de razão de verossimilhanças**. Um teste de razão de verossimilhanças,  $\delta_k$ , é um teste que rejeita  $H_0$  se  $\Lambda(\mathbf{x}) \leq k$  para uma constante  $k$ .*

**Teorema 23 (Teorema de Wilks)** Suponha que temos um espaço de parâmetros com  $k$  coordenadas,  $\theta = (\theta_1, \dots, \theta_n)$  e desejamos testar a hipótese (simples) da forma

$$H_0 : \theta_j = \theta_0^j, \quad j = 1, \dots, k,$$

$$H_1 : \theta_j \neq \theta_0^j, \quad j = 1, \dots, k.$$

Então, sob condições de regularidade, temos que, à medida que  $n \rightarrow \infty$ ,

$$-2 \log \Lambda(\mathbf{x}) \xrightarrow{d} X^2(k)$$

## Aula 18: Teste t I

**Definição 47 (Teste não viesado)** Suponha que desejamos testar a hipótese

$$H_0 : \theta \in \Omega_0,$$

$$H_1 : \theta \in \Omega_1,$$

através do teste  $\delta$ . Dizemos que  $\delta$  é **não-viesado** se (e somente se) para  $\theta \in \Omega_0$  e  $\theta' \in \Omega_1$ , vale

$$\pi(\theta \mid \delta) \leq \pi(\theta' \mid \delta),$$

ou seja, se a função poder é pelo menos tão grande no espaço onde  $H_0$  é falsa ( $\Omega_1$ ) quando no espaço em que  $H_0$  é verdadeira ( $\Omega_0$ ).

**Definição 48 (Teste t)** Um teste  $\delta_c$  que rejeita  $H_0$  se  $U \geq c$  (equiv.  $U \leq c$ ), com  $c = T^{-1}(1 - \alpha_0; n - 1)$  é chamado de um **teste t** (unicaudal) de tamanho  $\alpha_0$ .

**Teorema 24 (Propriedades do teste t)** Suponha que  $\delta_c$  rejeita  $H_0$  se  $U \geq c$ . Então

- $\mu = \mu_0 \implies \pi(\mu, \sigma^2 \mid \delta_c) = \alpha_0$
- $\mu < \mu_0 \implies \pi(\mu, \sigma^2 \mid \delta_c) < \alpha_0$
- $\mu > \mu_0 \implies \pi(\mu, \sigma^2 \mid \delta_c) > \alpha_0$
- $\lim_{\mu \rightarrow -\infty} \pi(\mu, \sigma^2 \mid \delta_c) = 0$
- $\lim_{\mu \rightarrow +\infty} \pi(\mu, \sigma^2 \mid \delta_c) = 1$
- $\delta_c$  é não-viesado e tem tamanho  $\alpha_0$ .

**Teorema 25 (P-valor para um teste t unicaudal)** Suponha que observarmos  $U = u$  e seja  $T(\cdot, n - 1)$  a f.d.a. de uma distribuição  $t$  de Student com  $n - 1$  graus de liberdade. Para a hipótese

$$H_0 : \mu \geq \mu_0,$$

$$H_1 : \mu < \mu_0,$$

o  $p$ -valor vale  $T(u; n - 1)$ , enquanto para a hipótese

$$H_0 : \mu \leq \mu_0,$$

$$H_1 : \mu > \mu_0,$$

o  $p$ -valor vale  $1 - T(u; n - 1)$ .

## Aula 19: Teste t II

**Teorema 26 (Teste pareado)** *Sejam amostras  $\mathbf{X}$  e  $\mathbf{Y}$  (antes e depois), tais que  $X_i \sim \text{Normal}(\mu_1, \sigma^2)$  e  $Y_i \sim \text{Normal}(\mu_2, \sigma^2)$ , a hipótese*

$$H_0 : \mu_1 \leq \mu_2$$

$$H_1 : \mu_1 > \mu_2$$

*Pode ser modelada com a variável  $Z_i = X_i - Y_i$  ( $Z_i \sim \text{Normal}(\mu_Z = \mu_1 - \mu_2, 2\sigma^2)$ ), então podemos testar hipóteses sobre  $\mu_Z$  a partir de  $\mathbf{Z}$*

$$H_0 : \mu_Z \leq 0$$

$$H_1 : \mu_Z > 0$$

**Teorema 27 (Teste t para duas amostras)** *Considere  $\mathbf{X} = \{X_1, \dots, X_m\}$  e  $\mathbf{Y} = \{Y_1, \dots, Y_n\}$ , queremos estudar a diferença das médias. Modelando em distribuição normal  $X_i \sim \text{Normal}(\mu_1, \sigma_1^2)$ ,  $i = 1, \dots, m$  e  $Y_j \sim \text{Normal}(\mu_2, \sigma_2^2)$ ,  $j = 1, \dots, n$ . Sob a premissa de homogeneidade  $\sigma_1^2 = \sigma_2^2 = \sigma^2$ , podemos testar a hipótese*

$$H_0 : \mu_1 \leq \mu_2$$

$$H_1 : \mu_1 > \mu_2$$

*computando a estatística*

$$U = \frac{\sqrt{m+n-2}(\bar{X}_m - \bar{Y}_n)}{\sqrt{(\frac{1}{m} + \frac{1}{n})(S_X^2 + S_Y^2)}}$$

*onde  $\bar{X}_m$  e  $\bar{Y}_n$  são as médias e  $S_X^2$  e  $S_Y^2$  são a soma das variâncias.*

**Teorema 28 (Relaxando a premissa de homogeneidade)** *Do teorema acima, podemos relaxar a premissa de igualdade das variâncias assumindo que  $\sigma_2^2 = k\sigma_1^2$ , então a estatística teste vale*

$$U = \frac{\sqrt{m+n-2}(\bar{X}_m - \bar{Y}_n)}{\sqrt{(\frac{1}{m} + \frac{k}{n})(S_X^2 + \frac{S_Y^2}{n})}}$$

## Aula 20: Teste f

**Definição 49 (A distribuição F)** *Sejam  $Y \sim \text{Qui-quadrado}(m)$  e  $W \sim \text{Qui-quadrado}(n)$ . Então*

$$X = \frac{Y/m}{W/n},$$

*tem distribuição F com m e n graus de liberdade, com f.d.p.*

$$f_X(x) = \frac{\Gamma(\frac{m+n}{2})m^{m/2}n^{n/2}}{\Gamma(\frac{n}{2})\Gamma(\frac{m}{2})} \cdot \frac{x^{m/2-1}}{(mx+n)^{(m+n)/2}}, \quad x > 0,$$

**Teorema 29 (Propriedades da distribuição F)** *Propriedades para a distribuição F:*

1. Se  $X \sim F(m, n)$ , então  $\frac{1}{X} \sim F(n, m)$ ;
2. Se  $Y \sim \text{Student}(n)$ , então  $Y^2 \sim F(1, n)$ .

**Teorema 30 (Igualdade de duas variâncias)** Suponha  $X_i \sim \text{Normal}(\mu_1, \sigma_1^2)$ ,  $i = 1, \dots, m$  e  $Y_j \sim \text{Normal}(\mu_2, \sigma_2^2)$ ,  $j = 1, \dots, n$ . Queremos testar

$$H_0 : \sigma_1^2 \leq \sigma_2^2$$

$$H_1 : \sigma_1^2 > \sigma_2^2$$

Para isso, vamos computar a estatística de teste

$$V = \frac{S_X^2/(m-1)}{S_Y^2/(n-1)}$$

onde  $S_X^2 = \sum_{i=1}^m (X_i - \bar{X}_m)^2$  e  $S_Y^2 = \sum_{j=1}^n (Y_j - \bar{Y}_n)^2$

**Definição 50 (O teste F)** O teste  $F$  de homogeneidade (igualdade de variâncias) é o teste  $\delta_c$  que rejeita  $H_0$  de  $V \geq c$ , para uma constante positiva  $c$ .

**Teorema 31 (A distribuição de V)** Seja  $V = \frac{S_X^2/(m-1)}{S_Y^2/(n-1)}$ , então:

$$\frac{\sigma_2^2}{\sigma_1^2} V \sim F(m-1, n-1).$$

Além disso, se  $\sigma_1^2 = \sigma_2^2$ ,  $V \sim F(m-1, n-1)$ .

## Aula 21: Regressão Linear I

**Teorema 32 (A linha de mínimos quadrados)** Sejam  $(x_1, y_1), \dots, (x_n, y_n)$  uma coleção de  $n$  pontos. Suponha que estamos interessados na reta

$$y_i = \beta_0 + \beta_1 x_i. \quad (27)$$

Os valores dos coeficientes que minimizam a soma de quadrados são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x},$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

**Definição 51 (Modelo linear)** Podemos construir um modelo estatístico explícito para a relação entre as variáveis  $X$  e  $Y$ :

$$E[Y \mid X = x_1, \dots, x_P] = \beta_0 + \beta_1 x_1 + \dots + \beta_P x_P \quad (28)$$

Podemos então idealizar o seguinte modelo

$$Y_i = \beta_0 + \sum_{j=1}^P \beta_j x_{ij} + \varepsilon_i, \quad \varepsilon \sim \text{Normal}(0, \sigma^2).$$

## Aula 22: Regressão Linear II

**Teorema 33 (EMV para os coeficientes de uma regressão linear (simples))** *Sob as premissas já listadas, os estimadores de máxima verossimilhança para  $\theta = (\beta_0, \beta_1, \sigma^2)$  são*

$$\begin{aligned}\hat{\beta}_{0EMV} &= \bar{y} - \hat{\beta}_{1EMV}\bar{x}, \\ \hat{\beta}_{1EMV} &= \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \\ \hat{\sigma}_{EMV}^2 &= \frac{1}{n} \sum_{i=1}^n \left( y_i - (\hat{\beta}_{0EMV} + \hat{\beta}_{1EMV}x_i) \right)^2,\end{aligned}$$

*ou seja, os estimadores de máxima verossimilhança dos coeficientes minimizam a soma de quadrados da reta estimada.*

**Teorema 34 (Distribuição amostral dos estimadores dos coeficientes)**

$$\begin{aligned}\hat{\beta}_{0EMV} &\sim \text{Normal} \left( \beta_0, \sigma^2 \left( \frac{1}{n} + \frac{\bar{x}^2}{s_X^2} \right) \right), \\ \hat{\beta}_{1EMV} &\sim \text{Normal} \left( \beta_1, \frac{\sigma^2}{s_X^2} \right), \\ \text{Cov}(\hat{\beta}_{0EMV}, \hat{\beta}_{1EMV}) &= -\frac{\bar{x}\sigma^2}{s_X^2},\end{aligned}$$

onde  $s_x = \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}$ .

**Teorema 35 (Intervalos de confiança para os coeficientes de uma regressão linear)** *Podemos computar intervalos de confiança para os coeficientes da regressão linear de maneira muito similar ao que já vimos para o caso da média da Normal*

$$\begin{aligned}\hat{\beta}_0 \pm \hat{\sigma}'c\sqrt{\frac{1}{n} + \frac{\bar{x}^2}{s_x^2}} \quad \text{e} \quad \hat{\beta}_1 \pm c\frac{\hat{\sigma}'}{s_x}, \\ \hat{\beta}_0 + \hat{\beta}_1 x_{pred} \pm c\hat{\sigma}'\sqrt{\frac{1}{n} + \frac{(x_{pred} - \bar{x})^2}{s_x^2}}\end{aligned}$$

onde  $c = T^{-1}(1 - \frac{\alpha_0}{2}; n - 2)$  e

$$\hat{\sigma}' := \sqrt{\frac{\sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2}{n - 2}}.$$

**Definição 52 (Testes de hipóteses para o coeficiente angular)** *Em geral, estamos interessados em testar a hipótese*

$$\begin{aligned}H_0 : \beta_1 &= \beta^*, \\ H_1 : \beta_1 &\neq \beta^*.\end{aligned}$$

*Para tanto, podemos computar a estatística*

$$U_1 = s_x \frac{\hat{\beta}_1 - \beta^*}{\hat{\sigma}'}, \tag{29}$$

e computar o  $p$ -valor como

$$P(U_1 \geq |u_1|) + P(U_1 \leq -|u_1|). \quad (30)$$

Notando que  $U_1$  tem distribuição  $t$  de Student com  $n - 2$  graus de liberdade sob  $H_0$ , podemos computar o  $p$ -valor exatamente.

Resultados bem similares valem para testar hipóteses sobre  $\beta_0$  ou  $\hat{Y}$ .

**Teorema 36 (Predição pontual)** Suponha que queremos prever o valor de  $Y$  para um certo  $x_{pred}$  que não foi observado no experimento. Podemos compor nossa predição (pontual) como

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x_{pred}. \quad (31)$$

Onde a predição tem erro quadrático médio (EQM) igual a

$$E[(\hat{Y} - Y)^2] = \sigma^2 \left( 1 + \frac{1}{n} + \frac{(x_{pred} - \bar{x})^2}{s_X^2} \right).$$

**Teorema 37 (Intervalos de predição para  $\hat{Y}$ )** A probabilidade de  $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x_{pred}$  estar no intervalo

$$\hat{Y} \pm T^{-1}\left(1 - \frac{\alpha_0}{2}; n - 2\right) \hat{\sigma}' \sqrt{\left[1 + \frac{1}{n} + \frac{(x_{pred} - \bar{x})^2}{s_X^2}\right]},$$

é  $1 - \alpha_0$ .