

Notas de aulas pelos slides (para A2)

Distribuição de média e variância amostrais

- Se $X_1, \dots, X_n \sim \text{Normal}(\mu, \sigma^2)$, então
 $\bar{X}_n \sim \text{Normal}(\mu, \frac{\sigma^2}{n})$
 $S_n^2 \sim \text{Gamma}\left(\frac{n-1}{2}, \frac{n}{2\sigma^2}\right)$
- Seja $Y \sim \text{Qui-quadrado}(m)$ e $Z \sim \text{Normal}(0,1)$ e
$$X = \frac{Z}{\sqrt{\frac{Y}{m}}}$$

então X é uma **t de Student** com n graus de liberdade, e

$$f_X(x) = \frac{\Gamma\left(\frac{m+1}{2}\right)}{\sqrt{m\pi} \Gamma\left(\frac{m}{2}\right)} \left(1 + \frac{x^2}{m}\right)^{-\frac{m+1}{2}}, x \in (-\infty, \infty)$$

- Se $\hat{\sigma}^2 = \frac{(\sum (X_i - \bar{X}_n)^2)^2}{n-1}$ (estimador), então
$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\hat{\sigma}^2} \sim \text{Student}(n-1)$$

Intervalos de confiança

- Seja $X = \{X_1, \dots, X_n\}$, cada uma com p.d.f. $f(x|\theta)$, e considere $g(\theta)$. Sejam $A(X)$ e $B(X)$ estatísticas tais que
$$P\{A(X) < g(\theta) < B(X)\} \geq \gamma$$

Então $I(X) = (A(X), B(X))$ é um **intervalo de confiança** de 100. γ %

Definimos intervalos de **confiança unilateral**, sendo $A(X) = -\infty$ ou $B(X) = \infty$ na definição acima.

- Seja $X = \{X_1, \dots, X_n\}$, cada uma com p.d.f. $f(x|\theta)$ e $V(X, \theta)$ uma v.a. com **mesma** distribuição para todo $\theta \in \Omega$.
Dig-se que $V(X, \theta)$ é uma **quantidade pivotal**.

- Seja $X = \{X_1, \dots, X_n\}$, tome $0 < \gamma_1 < 1$ e $\gamma_2 < \gamma_1$ de modo que $\gamma_2 - \gamma_1 = \gamma$, e seguindo estas condições.

$$A(X) = r(G^{-1}(\gamma_1), X)$$

$$B(X) = r(G^{-1}(\gamma_2), X)$$

são os limites de um intervalo de confiança 100. γ % para $g(\theta)$.

Testes de hipóteses

- Seja Ω um espaço de parâmetros e defina $\Omega_0, \Omega_1 \subset \Omega$ de modo que $\Omega_0 \cup \Omega_1 = \Omega$ e $\Omega_0 \cap \Omega_1 = \emptyset$

definimos

$$H_0 := \theta \in \Omega_0$$

$$H_1 := \theta \in \Omega_1$$

H_0 é a **hipótese nula** e H_1 é a **hipótese alternativa**. Se H_0 , digamos que rejeitamos a hipótese nula. Por outro lado, se $\theta \in \Omega_0$ digamos que não rejeitamos ou falhamos em rejeitar H_0 .

- Hipótese simples e hipótese compostas.

Uma hipótese da forma $H_0: \theta \leq \theta_0$ (ou $\theta \geq \theta_0$) é dita **unilateral**, enquanto hipóteses da forma $H_0: \theta \neq \theta_0$ são ditas **bilaterais**.

- O conjunto
$$S_c := \{x: |\bar{X}_n - \mu_0| \geq c\}$$

é chamado de **região crítica** do teste.

- Seja S um procedimento de aceitação / rejeição. A **função poder** é definida

$$\pi(\theta|S) := P(X \in S, |\theta) = P(T \in R|\theta), \theta \in \Omega$$

- Tipos de erros**

Nome	Erro cometido
Erro tipo I	Rejeitar H_0 quando ela é verdadeira.
Erro tipo II	Falhar em rejeitar H_0 quando ela é falsa.

- Digamos que um teste, S , tem **tamanho** ou **nível de significância** $\alpha(S)$, com

$$\alpha(S) := \sup_{\theta \in \Omega_0} \pi(\theta|S)$$

- Para cada t , seja S_t o teste que rejeita H_0 se $T \geq t$. Então, quando $T = t$, o **p-valor** vale

$$p(t) := \sup_{\theta \in \Omega_0} \pi(\theta|S_t) = \sup_{\theta \in \Omega_0} P(T \geq t|\theta).$$

- ou seja, o p-valor é o tamanho do teste S_t .

Razões de verossimilhanças

- Intervalos de confiança e testes são equivalentes**

- Se um conjunto aleatório $w(X)$ satisfaz

$$P(g(\theta) \in w(X) | \theta = \theta_0) \geq \gamma, \forall \theta_0 \in \Omega$$

então chamamos $w(X)$ de um **conjunto de confiança** para $g(\theta)$.

• Se $W(X)$ é um conjunto de confiança para uma função de interesse $g(\theta)$. Então $\forall g_0$ assumido por $g(\theta)$, $\exists \delta_{g_0}$, de nível α_0 que rejeita $H_0: g(\theta) = g_0 \Leftrightarrow g(\theta_0) = g_0 \in W(X)$.

• A estatística

$$\Lambda(x) = \frac{\sup_{\theta \in \Omega_0} f_n(x | \theta)}{\sup_{\theta \in \Omega} f_n(x | \theta)},$$

é chamada uma **estatística de razão de verossimilhança**. Um **teste de razão de verossimilhança**, S_K , é um teste que rejeita H_0 se $\Lambda(x) \leq K$ para K constante.

• Pelo **Teorema de Wilks**, a medida que a amostra aumenta ($n \rightarrow \infty$), então $-2 \log \Lambda(x) \xrightarrow{d} \chi^2(K)$.

Teste t

• Digamos que S é **não-verdade** se e somente se para $\theta \in \Omega_0$ e $\theta' \in \Omega_1$, vale $\pi(\theta | S) \leq \pi(\theta' | S)$

ou seja, se a função poder é pelo menos tão grande no espaço onde H_0 é falsa (Ω_1) quanto no espaço em que H_0 é verdadeira (Ω_0).

• Um teste S_c que rejeita H_0 se $U \geq c$ ($U \leq c$), com $c = T^{-1}(1 - \alpha_0; n-1)$ é chamado **teste t** de tamanho α_0 .

• Seja $U = U$ e $T(\cdot; n-1)$ a f.d.a. de distribuição t de Student com $n-1$ graus. Para a hipótese $H_0: \mu \geq \mu_0$, $H_1: \mu < \mu_0$, então o p-valor vale $T(U; n-1)$.

Teste t pareado

• Considere $X = \{X_1, \dots, X_m\}$ e $Y = \{Y_1, \dots, Y_n\}$, para estudar a **diferença das médias para duas amostras**. Modelando em distribuição normal $X_i \sim \text{Normal}(\mu_1, \sigma_1^2)$ e $Y_i \sim \text{Normal}(\mu_2, \sigma_2^2)$, sob a premissa de homogeneidade $\sigma_1^2 = \sigma_2^2 = \sigma^2$, podemos testar a hipótese

$$H_0: \mu_1 \leq \mu_2$$

$$H_1: \mu_1 > \mu_2$$

computando a estatística

$$U = \frac{\sqrt{m+n-2} (\bar{X}_m - \bar{Y}_n)}{\sqrt{(\frac{1}{m} + \frac{1}{n}) (S_x^2 + S_y^2)}}$$

• o teste t é não-verdade e pode ser computado como um teste de razão de verossimilhança.

Testes para igualdade de variâncias

• Seja $Y \sim \text{Qui-quadrado}(m)$ e $W \sim \text{Qui-quadrado}(n)$, então

$$X = \frac{Y/m}{W/n}$$

tem **distribuição F** com m e n graus de liberdade.

$$X \sim F(m, n) \Rightarrow \frac{1}{X} \sim F(n, m)$$

$$Y \sim \text{Student}(n) \Rightarrow Y^2 \sim F(1, n)$$

• Suponha $X_i \sim \text{Normal}(\mu_1, \sigma_1^2)$ e $Y \sim \text{Normal}(\mu_2, \sigma_2^2)$, queremos testar a **diferença das variâncias**.

$$H_0: \sigma_1^2 \leq \sigma_2^2,$$

$$H_1: \sigma_1^2 > \sigma_2^2$$

para isso basta computar a estatística.

• O **teste F** de homogeneidade (igualdade de variâncias) é o teste S_c que rejeita H_0 se $V \geq c$, para uma constante positiva c .

$$\text{Seja } V = \frac{S_x^2 / (m-1)}{S_y^2 / (n-1)}, \text{ então:}$$

$$\frac{\sigma_2^2}{\sigma_1^2} V \sim F(m-1, n-1)$$

Regressão Linear

• Sejam (X_i, Y_i) n pontos e queremos a **reta**

$$Y_i = \beta_0 + \beta_1 X_i$$

os valores que minimizam a soma de quadrados

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

$$\hat{\beta}_1 = \frac{\sum (Y_i - \bar{Y})(X_i - \bar{X})}{\sum (X_i - \bar{X})^2}$$

• Podemos construir um modelo estatístico explícito para a relação entre as variáveis X e Y :

$$Y_i = \beta_0 + \sum \beta_j X_{ij} + \epsilon_i, \epsilon_i \sim N(0, \sigma^2)$$

- Sobre as premissas: conhecimento do estimador, normalidade, linearidade na média, variância comum e independência. Os estimadores de máxima verossimilhança para $\theta = (\beta_0, \beta_1, \sigma^2)$ não

$$\hat{\beta}_{0EMV} = \bar{y} - \hat{\beta}_{1EMV} \bar{x}$$

$$\hat{\beta}_{1EMV} = \frac{\sum (y_i - \bar{y})(x_i - \bar{x})}{\sum (x_i - \bar{x})^2}$$

$$\hat{\sigma}_{EMV}^2 = \frac{1}{n} \sum \left(y_i - \left(\hat{\beta}_{0EMV} - \hat{\beta}_{1EMV} \bar{x} \right) \right)^2$$

- Distribuições dos estimadores:

$$\hat{\beta}_{0EMV} \sim \text{Normal} \left(\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum x_i^2} \right) \right)$$

$$\hat{\beta}_{1EMV} \sim \text{Normal} \left(\beta_1, \frac{\sigma^2}{\sum x_i^2} \right)$$

$$\text{Cov}(\hat{\beta}_{0EMV}, \hat{\beta}_{1EMV}) = -\frac{\bar{x} \sigma^2}{\sum x_i^2}$$

onde $\sum x_i = \sqrt{\sum (x_i - \bar{x})^2}$

- Intervalos de confiança para uma regressão linear:

$$\hat{\beta}_0 \pm \hat{\sigma}' c \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum x_i^2}} = \hat{\beta}_1 \pm c \frac{\hat{\sigma}'}{\sum x_i^2}$$

$$\hat{\beta}_0 + \hat{\beta}_1 x_{pred} \pm c \hat{\sigma}' \sqrt{\frac{1}{n} + \frac{(x_{pred} - \bar{x})^2}{\sum x_i^2}}$$

onde $c = T^{-1}(1 - \frac{\alpha_0}{2}; n-2)$ e

$$\hat{\sigma}' := \sqrt{\frac{\sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2}{n-2}}$$

- Para testar uma hipótese para o coeficiente angular, testamos

$$H_0: \beta_1 = \beta^*$$

$$H_1: \beta_1 \neq \beta^*$$

podemos utilizar a estatística

$$U_1 = s_x \frac{\hat{\beta}_1 - \beta^*}{\hat{\sigma}'}$$

- Se $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_{pred}$, então a EQM é

$$E[(\hat{y} - y)^2] = \sigma^2 \left(1 + \frac{1}{n} + \frac{(x_{pred} - \bar{x})^2}{\sum x_i^2} \right)$$

- A probabilidade de $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_{pred}$ estar no intervalo

$$\hat{y} \pm T^{-1}(1 - \frac{\alpha_0}{2}; n-2) \hat{\sigma}' \sqrt{1 + \frac{1}{n} + \frac{(x_{pred} - \bar{x})^2}{\sum x_i^2}}$$

é $1 - \alpha_0$.